

第一章 数值计算

1.1 绪论

定义 1.1.1. 若 A 非奇异, 称 $cond(A) = \|A\| \|A^{-1}\|$ 为 A 的条件数。 $cond(A) \geq 1$, 当 A 为正交矩阵时 $cond(A) = 1$ 。

定理 1.1.1. 对于线性方程组 $Ax = b$

1. 设 $A(x + \delta x) = b + \delta b$, δx 收到 δb 的影响表示为

$$\frac{\|\delta x\|}{\|x\|} \leq cond(A) \frac{\|\delta b\|}{\|b\|}$$

2. 设 $(A + \delta A)(x + \delta x) = b + \delta b$, δx 收到 $\delta A, \delta b$ 的影响表示为

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{cond(A)}{1 - cond\left(\frac{\|\delta A\|}{\|A\|}\right)} \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right)$$

证明:

$$\begin{aligned} (A + \delta A)(x + \delta x) &= b + \delta b \\ (A + \delta A)\delta x &= b + \delta b - \cancel{Ax} + \delta A \cdot x = b + \delta A \cdot x \\ \delta x &= \underbrace{(A + \delta A)^{-1}}_{(I + \delta A A^{-1})^{-1}} (\delta b - \delta A \cdot x) \\ \|\delta x\| &= \|A^{-1}(I + \delta A A^{-1})^{-1}(\delta b - \delta A \cdot x)\| \\ &\leq \|A^{-1}\| \|(I + \delta A A^{-1})^{-1}\| \|\delta b - \delta A \cdot x\| \\ &\leq \|A^{-1}\| \frac{1}{1 - \|\delta A\| \|A^{-1}\|} \underbrace{\|\delta b\|}_{partA} + \underbrace{\|\delta A \cdot x\|}_{partB} \\ partB &= \|A^{-1}\| \|A\| \frac{1}{1 - \|\delta A\| \|A^{-1}\|} \frac{\|x\| \|\delta A\|}{\|A\|} \\ partA &= \|A^{-1}\| \frac{1}{1 - \|\delta A\| \|A^{-1}\|} \frac{\|\delta b\| \|Ax\|}{\|B\|} \leq \|A^{-1}\| \frac{1}{1 - \|\delta A\| \|A^{-1}\|} \frac{\|\delta b\| \|A\| \|x\|}{\|B\|} \\ \frac{\|\delta x\|}{\|x\|} &\leq \frac{cond(A)}{1 - cond\left(\frac{\|\delta A\|}{\|A\|}\right)} \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right) \end{aligned}$$

□

引理 1.1.2. 若 $A \in \mathbb{R}^{n \times n}$, 且 $\|A\| < 1$, 则

1. $I - A$ 非奇异
2. $(I - A)^{-1} = \sum_{k=0}^{\infty} A^k$
3. $\|(I - A)^{-1}\| \leq \frac{1}{1 - \|A\|}$

证明:

1. 若 $I - A$ 奇异, 则 $\exists x \neq 0$, s.t. $(I - A)x = 0$, 即 1 为 A 的特征值, 矛盾
2. $\sum_{k=0}^{\infty} A^k \cdot (I - A) = A^0 = I$
3. $\|(I - A)^{-1}\| = \|\sum_{k=0}^{\infty} A^k\| \leq \sum_{k=0}^{\infty} \|A^k\| \leq \sum_{k=0}^{\infty} \|A\|^k = \frac{1}{1 - \|A\|}$

□

注. 在数值分析中, 判断矩阵 A 是否病态 (即对微小扰动敏感) 通常不直接计算 A^{-1} (条件数), 而是依据以下经验准则:

1. 行列式很大或很小 (如某些行、列近似相关)

行列式 $\det(A)$ 的绝对值若远小于或远大于矩阵元素数量级的 n 次方, 可能预示病态。

解释: 行列式绝对值过小通常意味着矩阵的行或列向量近似线性相关, 导致其张成的“体积”很小, 矩阵接近奇异。

2. 元素间相差大数量级, 且无规则

若矩阵元素在数值上跨越多个数量级 (如 10^{-6} 与 10^3 共存), 且没有特定的分布模式 (如对角占优)。

解释: 这种巨大的尺度差异会在数值计算 (如消元法) 中放大舍入误差, 除非该矩阵具有特殊的、可补偿的结构。

3. 主元消去过程中出现小主元

在进行高斯消元时, 如果出现绝对值非常小的主元。

解释: 小主元意味着矩阵接近奇异, 在消元过程中需要用其去除其他大元素, 这会极大地放大原始数据中存在的微小误差。

4. 特征值相差大数量级

矩阵的特征值 λ_i 的绝对值分布范围极广, 即 $\max |\lambda_i| / \min |\lambda_i| \gg 1$ 。

解释: 对于对称矩阵, 这直接导致其条件数 $\kappa(A)$ 极大, 意味着矩阵在不同特征向量方向上的伸缩程度差异巨大, 从而对扰动非常敏感。

1.2 非线性方程求根

1.2.1 二分法 (对分法)

二分法两种终止条件:

1. 给定精度条件 $|f(x)| < \varepsilon$ **不适用情况:** 当函数在远离根的区域存在平坦区间 (即导数近似为零) 时, 即使当前点 x 离真实根 r 还很远, 也可能满足 $|f(x)| < \varepsilon$, 导致算法提前

终止, 返回一个错误解。

2. 区间长度条件 $b - a < \varepsilon$ 不适用情况: 当函数在根 r 附近数值上呈现陡峭跳变 (由于浮点舍入误差导致类似符号函数的行为) 时, 可能在迭代过程中因符号判断错误而将真根排除在区间之外。此时区间继续缩小至 $b - a < \varepsilon$, 但区间内不含根, 导致返回错误解。

二分法缺点:

1. 只能求单个根, 只能计算实根。
2. 即使 $f(x)$ 在 $[a, b]$ 上有根, 也未必有 $f(a)f(b) < 0$ 。

注. 常用 $\text{sgn}(f(a)) \cdot \text{sgn}(f(x)) > 0$ 代替 $f(a) \cdot f(x) > 0$ 的判断, 避免 $f(a) \cdot f(x) > 0$ 数值溢出。

1.2.2 不动点迭代法

定理 1.2.1. 若 $\varphi(x)$ 定义在 $[a, b]$ 上, 如果 $\varphi(x)$ 满足

1. 当 $x \in [a, b]$ 时有 $a \leq \varphi(x) \leq b$;
 2. $\varphi(x)$ 在 $[a, b]$ 上可导, 并且存在正数 $L < 1$, 使对任意的 $x \in [a, b]$, $|\varphi'(x)| \leq L$ 。
1. 则在 $[a, b]$ 上存在唯一的不动点 x^* , 即满足 $x^* = \varphi(x^*)$ 的点。
2. 迭代格式 $x_{k+1} = \varphi(x_k)$ 对任意的初值 $x_0 \in [a, b]$ 均收敛于 $\varphi(x)$ 的不动点 x^* 。
3. 并有误差估计式 $|x^* - x_k| \leq \frac{L^k}{1-L} |x_1 - x_0|$ 。

证明: (1) **存在性:** 令 $\psi(x) = x - \varphi(x)$, 则有

$$\psi(a) = a - \varphi(a) \leq 0, \quad \psi(b) = b - \varphi(b) \geq 0.$$

由介值定理, 存在 x^* , $a \leq x^* \leq b$, 使得

$$\psi(x^*) = x^* - \varphi(x^*) = 0 \quad \text{或} \quad x^* = \varphi(x^*).$$

唯一性 (反证法): 另一方面, 若另有 x^+ 满足 $x^+ = \varphi(x^+)$, 则由

$$|x^* - x^+| = |\varphi(x^*) - \varphi(x^+)| = |\varphi'(\xi)(x^* - x^+)| \leq L|x^* - x^+|, \quad \xi \in [a, b]$$

以及 $L < 1$, 得到 $x^* = x^+$ 。

(2) 当 $x_0 \in [a, b]$ 时可用归纳法证明, 迭代序列 $\{x_k\} \subset [a, b]$, 由微分中值定理

$$\begin{aligned} x_{k+1} - x^* &= \varphi(x_k) - \varphi(x^*) = \varphi'(\xi)(x_k - x^*) \leq L(x_k - x^*) \\ |x_{k+1} - x^*| &\leq L|x_k - x^*| = L|\varphi(x_{k-1}) - \varphi(x^*)| \leq L^2|x_{k-1} - x^*| \leq \cdots \leq L^{k+1}|x_0 - x^*| \end{aligned}$$

因为 $L < 1$, 所以当 $k \rightarrow \infty$ 时, $L^{k+1} \rightarrow 0$, $x_{k+1} \rightarrow x^*$, 迭代格式 $x_{k+1} = \varphi(x_k)$ 收敛。

(3) 误差估计:

$$|x_{k+1} - x_k| = |\varphi(x_k) - \varphi(x_{k-1})| \leq L|x_k - x_{k-1}| \leq \cdots \leq L^k|x_1 - x_0|.$$

设 k 固定, 对于任意的正整数 p 有

$$\begin{aligned} |x_{k+p} - x_k| &\leq |x_{k+p} - x_{k+p-1}| + |x_{k+p-1} - x_{k+p-2}| + \cdots + |x_{k+1} - x_k| \\ &\leq (L^{k+p-1} + L^{k+p-2} + \cdots + L^k)|x_1 - x_0| = \frac{L^k(1 - L^p)}{1 - L}|x_1 - x_0|. \end{aligned}$$

由于 p 的任意性及

$$\lim_{p \rightarrow \infty} x_{k+p} = x^*,$$

故有 $x^* = \varphi(x^*)$,

$$|x^* - x_k| \leq \frac{L^k}{1 - L}|x_1 - x_0|.$$

□

构造收敛迭代格式的两个要素

1. 选取合适的等价形式 $x = \varphi(x)$, 使得 $\varphi(x)$ 满足上述定理的条件。
2. 选取合适的初始值 x_0 。必需取自 x^* 的充分小邻域, 这个邻域大小决定于函数 $f(x)$, 以及做出的等价形式 $x = \varphi(x)$ 。

1.2.3 Newton 迭代法

Newton 迭代格式为

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}, \quad k = 0, 1, 2, \dots$$

Newton 迭代对应 $f(x) = 0$ 的迭代方程是 $\varphi(x) = x - \frac{f(x)}{f'(x)}$, $\varphi'(x) = \frac{f(x)f''(x)}{(f'(x))^2}$ 。

1. 若 α 是 $f(x)$ 的单根时, $f(\alpha) = 0$, $f'(\alpha) \neq 0$, 则有 $|\varphi'(x_0)| = 0$, 只要初值 x_0 足够接近 α , 则迭代收敛且收敛阶为 2。
2. 若 α 是 $f(x)$ 的 p 重根时设 α 为 $f(x)$ 的 p 重根时, 记

$$\begin{aligned} f(x) &= (x - \alpha)^p h(x) \\ \varphi(x) &= x - \frac{(x - \alpha)^p h(x)}{p(x - \alpha)^{p-1} h(x) + (x - \alpha)^p h'(x)} = x - \frac{(x - \alpha)h(x)}{ph(x) + (x - \alpha)h'(x)} \\ \varphi'(x) &= \frac{\left(1 - \frac{1}{p}\right) + (x - \alpha)\frac{2h'(x)}{ph(x)} + (x - \alpha)^2 \frac{h''(x)}{p^2 h(x)}}{\left[1 + (x - \alpha)\frac{h'(x)}{ph(x)}\right]^2} \\ \varphi'(\alpha) &= 1 - \frac{1}{p} \end{aligned}$$

仍然有 $|\varphi'(\alpha)| < 1$, 当初始值在根 α 附近, 迭代也收敛, 这是一阶迭代方法。

若 α 为 $f(x)$ 的 p 重根时, 这时取下面迭代格式, 仍是二阶方法

(a)

$$x_{k+1} = x_k - p \frac{f(x_k)}{f'(x_k)}, \quad k = 1, 2, \dots$$

(b) 取 $g(x) = \frac{f(x)}{f'(x)}$, 则迭代格式为

$$\begin{aligned} x_{k+1} &= x_k - \frac{g(x_k)}{g'(x_k)}, \quad k = 1, 2, \dots \\ &= x_k - \frac{f(x_k)f'(x_k)}{(f'(x_k))^2 - f(x_k)f''(x_k)} \end{aligned}$$

注. 如果 α 是 $f(x)$ 的 p 重根, 那么 α 是 $g(x)$ 的单根。因此, 对函数 $g(x)$ 进行 Newton 迭代, 能够恢复二阶收敛性。

1.2.4 弦截法

在 Newton 迭代格式中, 用差商代替导数, 并给定两个初值 x_0 和 x_1 , 得到弦截法迭代格式:

$$x_{k+1} = x_k - \frac{f(x_k)(x_k - x_{k-1})}{f(x_k) - f(x_{k-1})}, \quad k = 1, 2, \dots$$

弦截法的收敛阶为 $\frac{1+\sqrt{5}}{2} \approx 1.618$, 介于线性收敛和二次收敛之间。

1.2.5 对于非线性方程组的 Newton 方法

对于非线性方程组:

$$\mathbf{F}(\mathbf{x}) = \mathbf{0}, \quad \mathbf{F} : \mathbb{R}^n \rightarrow \mathbb{R}^n$$

Newton 迭代法的基本格式为: $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - [J_F(\mathbf{x}^{(k)})]^{-1}\mathbf{F}(\mathbf{x}^{(k)})$, 其中 $J_F(\mathbf{x})$ 是 Jacobi 矩阵:

$$J_F(\mathbf{x}) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \dots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \dots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}$$

为避免直接求逆矩阵, 实际计算采用解线性方程组的形式:

$$\begin{aligned} J_F(\mathbf{x}^{(k)})\Delta\mathbf{x}^{(k)} &= -\mathbf{F}(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} + \Delta\mathbf{x}^{(k)} \end{aligned}$$

newton_system.m 是我编写的 MATLAB 代码, 实现了用于求解非线性方程组的 Newton 迭代法:

代码 1.1: newton_system.m

```
1 function [solution, iterations, errors] = newton_system(f, vars, x0,
    max_iter, tol)
2     % 使用 Newton 迭代法求解非线性方程组
3     %
4     % 输入:
5     % f - 符号函数向量
6     % vars - 符号变量向量
```

```
7      % x0 - 初始猜测
8      % max_iter - 最大迭代次数 (默认: 50)
9      % tol - 容差 (默认: 1e-12)
10     %
11     % 输出:
12     % solution - 数值解
13     % iterations - 实际迭代次数
14     % errors - 每次迭代的误差历史
15
16     if nargin < 4
17         max_iter = 50;
18     end
19     if nargin < 5
20         tol = 1e-12;
21     end
22
23     % 计算 Jacobian 矩阵
24     J = jacobian(f, vars);
25
26     % 转换为数值函数句柄
27     f_func = matlabFunction(f, 'Vars', {vars});
28     J_func = matlabFunction(J, 'Vars', {vars});
29
30     x = x0;
31     errors = zeros(max_iter, 1);
32
33     for iterations = 1:max_iter
34         % 计算当前函数值和 Jacobian
35         f_val = f_func(x);
36         J_val = J_func(x);
37
38         % 计算误差
39         current_error = norm(f_val);
40         errors(iterations) = current_error;
41
42         % 检查收敛
43         if current_error < tol
44             break;
45         end
46
47         % Newton 迭代
48         delta_x = -J_val \ f_val;
49         x = x + delta_x;
50
51         % 检查步长是否太小
52         if norm(delta_x) < 1e-14
53             disp('delta_x 小于1e-14')
54             break;
```

```

55         end
56     end
57
58     solution = x;
59 end

```

我让 DeepSeek 帮我优化了代码，使用结构体管理求解器参数设置，并且可以根据输入函数类型（符号函数/函数句柄）自动选择 MATLAB 内置的 Jacobian 函数解析计算 Jacobi 矩阵，或者使用中心差分法计算 Jacobi 矩阵，见 newton_system_solver.m。

1.3 求解线性方程组的迭代方法

考虑线性方程组 $Ax = b$ ，将矩阵 A 分解为 $A = N - P$ ，其中 N 可逆，得到等价形式： $x = N^{-1}Px + N^{-1}b$ 。令 $M = N^{-1}P$ ， $g = N^{-1}b$ ，则原方程等价于： $x = Mx + g$

构造迭代格式：

$$x^{(k)} = Mx^{(k-1)} + g, \quad k = 1, 2, \dots$$

设迭代序列 $\{x^{(k)}\}$ 收敛于 x^* ，则对迭代式两边取极限得：

$$x^* = Mx^* + g,$$

即 x^* 是 $Ax = b$ 的解。

误差向量 $e^{(k)} = x^* - x^{(k)}$ 满足：

$$e^{(k)} = Me^{(k-1)} = M^2e^{(k-2)} = \dots = M^ke^{(0)},$$

$$\|e^{(k)}\| = \|M^ke^{(0)}\| \leq \|M^k\| \cdot \|e^{(0)}\|.$$

若 $\lim_{k \rightarrow \infty} \|M^k\| = 0$ ，则 $\lim_{k \rightarrow \infty} e^{(k)} = 0$ ，迭代收敛。

由线性代数定理知：

$$\lim_{k \rightarrow \infty} M^k = O \quad \Leftrightarrow \quad \rho(M) < 1,$$

其中 $\rho(M)$ 为 M 的谱半径。又因为 $\|M\| \geq \rho(M)$ ，所以若 $\|M\| < 1$ ，则 $\rho(M) < 1$ ，迭代收敛。

1.3.1 简单 Jacobi 迭代

设线性方程组 $Ax = b$ ，其中 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$ ，且 $a_{ii} \neq 0, (i = 1, 2, \dots, n)$ 。

将 A 分解为：

$$A = D + A - D$$

其中：

- $D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$ 为对角矩阵，设 D 可逆。

则

$$Ax = (D + A - D)x = b \Leftrightarrow Dx = (D - A)x + b$$

Jacobi 迭代法的迭代格式为：

1. 矩阵形式为:

$$\begin{aligned}
 x^{(k)} &= D^{-1}(D - A)x^{(k-1)} + D^{-1}b, \quad k = 1, 2, \dots \\
 \text{记 } R &= I - D^{-1}A, \quad g = D^{-1}b \\
 x^{(k)} &= Rx^{(k-1)} + g \\
 \text{即 } \begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \\ \vdots \\ x_n^{(k)} \end{pmatrix} &= \begin{pmatrix} 0 & r_{12} & \cdots & r_{1n} \\ r_{21} & 0 & \cdots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ r_{n1} & r_{n2} & \cdots & 0 \end{pmatrix} \begin{pmatrix} x_1^{(k-1)} \\ x_2^{(k-1)} \\ \vdots \\ x_n^{(k-1)} \end{pmatrix} + \begin{pmatrix} g_1 \\ g_2 \\ \vdots \\ g_n \end{pmatrix} \\
 r_{ij} &= -\frac{a_{ij}}{a_{ii}}, \quad g_i = \frac{b_i}{a_{ii}}, \quad r_{ii} = 0
 \end{aligned}$$

2. 分量形式为:

$$x_i^{(k)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k-1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \right), \quad i = 1, 2, \dots, n$$

迭代收敛的充分必要条件是:

$$\rho(R) < 1$$

其中 $\rho(R)$ 是 Jacobi 迭代矩阵的谱半径。

定理 1.3.1. 若 M 严格对角占优, 则 M 可逆。

证明: 设 M 严格行对角占优。若 M 不可逆, 则存在非零向量 $x = (x_1, \dots, x_n)^T$ 使 $Mx = 0$ 。取 $|x_i| = \max(|x_1|, \dots, |x_n|)$, 则:

$$|m_{ii}x_i| = \left| \sum_{j \neq i} m_{ij}x_j \right| \leq \sum_{j \neq i} |m_{ij}| \cdot |x_i| < |m_{ii}| \cdot |x_i|$$

矛盾。若 M 严格列对角占优, 则 M^T 严格行对角占优。综上, M 可逆。 □

定理 1.3.2. 若 A 严格对角占优, 则 Jacobi 迭代收敛。

证明:

若 A 严格行对角占优:

$$\rho(I - D^{-1}A) \leq \|I - D^{-1}A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j \neq i} \frac{|a_{ij}|}{|a_{ii}|} < 1$$

若 A 严格列对角占优:

$$\rho(I - D^{-1}A) = \rho(I - AD^{-1}) \leq \|I - AD^{-1}\|_1 = \max_{1 \leq j \leq n} \sum_{i \neq j} \frac{|a_{ij}|}{|a_{jj}|} < 1$$

注.

$$\begin{aligned}
 \det(D) \det(\lambda I - I + D^{-1}A) \det(D^{-1}) &= \det(\lambda I - I + AD^{-1}) \\
 \Leftrightarrow \text{特征值一致} &\Rightarrow \rho(I - D^{-1}A) = \rho(I - AD^{-1})
 \end{aligned}$$



代码 1.2: jacobi_iteration.m

```
1 function [x, iter, error_history] = jacobi_iteration(A, b, x0, max_iter, tol)
2     % 使用矩阵形式的Jacobi迭代法求解线性方程组  $Ax = b$ 
3     %
4     % 输入:
5     %   A - 系数矩阵 (n x n)
6     %   b - 右端向量 (n x 1)
7     %   x0 - 初始猜测向量 (n x 1)
8     %   max_iter - 最大迭代次数 (默认: 1000)
9     %   tol - 容差 (默认: 1e-6)
10    %
11    % 输出:
12    %   x - 数值解
13    %   iter - 实际迭代次数
14    %   error_history - 每次迭代的误差历史
15
16    if nargin < 4
17        max_iter = 1000;
18    end
19    if nargin < 5
20        tol = 1e-6;
21    end
22
23    n = length(b);
24    x = x0;
25    error_history = zeros(max_iter, 1);
26
27    % 提取对角矩阵D
28    D = diag(diag(A));
29
30    % 计算迭代矩阵  $R = I - D^{-1}A$  和向量  $g = D^{-1}b$ 
31    R = eye(n) - D \ A;
32    g = D \ b;
33
34    for iter = 1:max_iter
35        % Jacobi迭代:  $x(k) = R * x(k-1) + g$ 
36        x_new = R * x + g;
37
38        % 计算相对误差
39        error = norm(x_new - x, inf) / norm(x_new, inf);
40        error_history(iter) = error;
41
42        % 更新解
43        x = x_new;
44
45        % 检查收敛
```

```

46         if error < tol
47             break;
48         end
49     end
50
51     % 截断误差历史数组
52     error_history = error_history(1:iter);
53 end

```

1.3.2 Gauss-Seidel 迭代

设线性方程组 $Ax = b$, 其中 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$, 且 $a_{ii} \neq 0, (i = 1, 2, \dots, n)$ 。
将 A 分解为:

$$A = D + L + U$$

其中:

- $D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$ 为对角矩阵
- L 为严格下三角部分 ($l_{ij} = a_{ij}$ for $i > j$, $l_{ij} = 0$ for $i \leq j$)
- U 为严格上三角部分 ($u_{ij} = a_{ij}$ for $i < j$, $u_{ij} = 0$ for $i \geq j$)

则

$$Ax = (D + L + U)x = b \Leftrightarrow (D + L)x = -Ux + b$$

Gauss-Seidel 迭代法的迭代格式为:

1. 矩阵形式为:

$$x^{(k)} = -(D + L)^{-1}Ux^{(k-1)} + (D + L)^{-1}b, \quad k = 1, 2, \dots$$

$$\text{记 } G = -(D + L)^{-1}U, \quad g = (D + L)^{-1}b$$

$$x^{(k)} = Gx^{(k-1)} + g$$

2. 分量形式为:

$$x_i^{(k)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \right), \quad i = 1, 2, \dots, n$$

迭代收敛的充分必要条件是:

$$\rho(G) < 1$$

其中 $\rho(G)$ 是 Gauss-Seidel 迭代矩阵的谱半径。

定理 1.3.3. 若 A 严格对角占优, 则 Gauss-Seidel 迭代收敛。

证明: 设 A 严格行对角占优。记误差向量 $e^{(k)} = x^* - x^{(k)}$, 其中 x^* 为精确解。

由 Gauss-Seidel 迭代格式:

$$e^{(k)} = -(D + L)^{-1}Ue^{(k-1)}$$

设 $\|e^{(k)}\|_\infty = |e_i^{(k)}|$, 则:

$$\begin{aligned} |e_i^{(k)}| &= \left| -\frac{1}{a_{ii}} \left(\sum_{j=1}^{i-1} a_{ij} e_j^{(k)} + \sum_{j=i+1}^n a_{ij} e_j^{(k-1)} \right) \right| \\ &\leq \frac{1}{|a_{ii}|} \left(\sum_{j=1}^{i-1} |a_{ij}| \cdot |e_j^{(k)}| + \sum_{j=i+1}^n |a_{ij}| \cdot |e_j^{(k-1)}| \right) \\ &\leq \frac{1}{|a_{ii}|} \left(\sum_{j=1}^{i-1} |a_{ij}| \cdot \|e^{(k)}\|_\infty + \sum_{j=i+1}^n |a_{ij}| \cdot \|e^{(k-1)}\|_\infty \right) \end{aligned}$$

整理得:

$$\|e^{(k)}\|_\infty \leq \frac{\sum_{j=i+1}^n |a_{ij}|}{|a_{ii}| - \sum_{j=1}^{i-1} |a_{ij}|} \|e^{(k-1)}\|_\infty$$

由于 A 严格对角占优, 有:

$$\frac{\sum_{j=i+1}^n |a_{ij}|}{|a_{ii}| - \sum_{j=1}^{i-1} |a_{ij}|} < 1$$

故 $\|e^{(k)}\|_\infty \rightarrow 0$, Gauss-Seidel 迭代收敛。 □

定理 1.3.4. 若 A 对称正定, 则 Gauss-Seidel 迭代收敛。

证明: 为定理 1.3.6 的特例。 □

代码 1.3: gauss_seidel_iteration.m

```
1 function [x, iter, error_history] = gauss_seidel_iteration(A, b, x0,
    max_iter, tol)
2 % 使用矩阵形式的Gauss-Seidel迭代法求解线性方程组 Ax = b
3 %
4 % 输入:
5 %   A - 系数矩阵 (n x n)
6 %   b - 右端向量 (n x 1)
7 %   x0 - 初始猜测向量 (n x 1)
8 %   max_iter - 最大迭代次数 (默认: 1000)
9 %   tol - 容差 (默认: 1e-6)
10 %
11 % 输出:
12 %   x - 数值解
13 %   iter - 实际迭代次数
14 %   error_history - 每次迭代的误差历史
15
16 if nargin < 4
17     max_iter = 1000;
18 end
19 if nargin < 5
20     tol = 1e-6;
```

```

21     end
22
23     n = length(b);
24     x = x0;
25     error_history = zeros(max_iter, 1);
26
27     % 矩阵分解: A = D + L + U
28     D = diag(diag(A));           % 对角部分
29     L = tril(A, -1);             % 严格下三角部分
30     U = triu(A, 1);              % 严格上三角部分
31
32     % 计算迭代矩阵 G = -(D+L)^(-1)U 和向量 g = (D+L)^(-1)b
33     % 注意: 实际计算中避免直接求逆, 使用前向替换
34     D_sum_L = D + L;
35
36     for iter = 1:max_iter
37         x_old = x;
38
39         % Gauss-Seidel迭代: (D+L)x(k) = -Ux(k-1) + b
40         % 使用前向替换求解 (D+L)x(k) = b - U*x_old
41
42         rhs = b - U * x_old;
43
44         % 前向替换求解下三角系统
45         x = zeros(n, 1);
46         for i = 1:n
47             x(i) = (rhs(i) - D_sum_L(i, 1:i-1) * x(1:i-1)) / D_sum_L(i, i);
48         end
49
50         % 计算相对误差
51         error = norm(x - x_old, inf) / norm(x, inf);
52         error_history(iter) = error;
53
54         % 检查收敛
55         if error < tol
56             break;
57         end
58     end
59
60     % 截断误差历史数组
61     error_history = error_history(1:iter);
62 end

```

1.3.3 松弛迭代

设线性方程组 $Ax = b$, 其中 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$, 且 $a_{ii} \neq 0, (i = 1, 2, \dots, n)$ 。

将 A 分解为:

$$A = D + L + U$$

其中:

- $D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$ 为对角矩阵
- L 为严格下三角部分
- U 为严格上三角部分

松弛迭代法的迭代格式为:

1. 矩阵形式为:

$$x^{(k)} = (1 - \omega)x^{(k-1)} + \omega(-D^{-1}Lx^{(k)} - D^{-1}Ux^{(k-1)} + D^{-1}b), \quad k = 1, 2, \dots$$

$$\text{记 } \tilde{L} = -D^{-1}L, \quad \tilde{U} = -D^{-1}U, \quad g = D^{-1}b$$

$$x^{(k)} = (1 - \omega)Ix^{(k-1)} + \omega(\tilde{L}x^{(k)} + \tilde{U}x^{(k-1)} + g)$$

$$\text{记 } L_\omega = (I + \omega\tilde{L})^{-1}[(1 - \omega)I + \omega\tilde{U}], \quad g_\omega = \omega(I + \omega\tilde{L})^{-1}g$$

$$x^{(k)} = L_\omega x^{(k-1)} + g_\omega$$

2. 分量形式为:

$$x_i^{(k)} = (1 - \omega)x_i^{(k-1)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} \right), \quad i = 1, 2, \dots, n$$

其中 $\omega > 0$ 为松弛因子:

- 当 $0 < \omega < 1$ 时, 称为欠松弛方法
- 当 $\omega = 1$ 时, 即为 Gauss-Seidel 迭代
- 当 $1 < \omega < 2$ 时, 称为超松弛方法 (SOR)

迭代收敛的充分必要条件是:

$$\rho(L_\omega) < 1$$

其中 $\rho(L_\omega)$ 是松弛迭代矩阵的谱半径。

定理 1.3.5. 对任意矩阵 A , SOR 迭代收敛的必要条件是:

$$0 < \omega < 2$$

证明: 设 L_ω 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 则:

$$\det(L_\omega) = \prod_{i=1}^n \lambda_i = \det[(D + \omega L)^{-1}] \det[(1 - \omega)D - \omega U]$$

由于 $D + \omega L$ 和 $(1 - \omega)D - \omega U$ 都是三角矩阵, 有:

$$\det(L_\omega) = \frac{\prod_{i=1}^n [(1 - \omega)a_{ii}]}{\prod_{i=1}^n a_{ii}} = (1 - \omega)^n$$

因此:

$$|\det(L_\omega)| = |1 - \omega|^n = \left| \prod_{i=1}^n \lambda_i \right| \leq [\rho(L_\omega)]^n$$

若迭代收敛, 则 $\rho(L_\omega) < 1$, 故 $|1 - \omega| < 1$, 即 $0 < \omega < 2$ 。

□

定理 1.3.6. 若 A 对称正定, 且 $0 < \omega < 2$, 则 SOR 迭代收敛。

证明: 设 λ 为 L_ω 的特征值, x 为对应特征向量, 则:

$$L_\omega x = \lambda x \Rightarrow (D + \omega L)^{-1}[(1 - \omega)D - \omega U]x = \lambda x$$

整理得:

$$[(1 - \omega)D - \omega U]x = \lambda(D + \omega L)x$$

考虑二次型:

$$x^H[(1 - \omega)D - \omega U]x = \lambda x^H(D + \omega L)x$$

由于 A 对称正定, $U = L^T$, 令:

$$x^H D x = \alpha > 0, \quad x^H L x = \beta + i\gamma$$

则原式可写为:

$$\begin{aligned} (1 - \omega)\alpha - \omega(\beta - i\gamma) &= \lambda(\alpha + \omega(\beta + i\gamma)) \Leftrightarrow \lambda = \frac{(1 - \omega)\alpha - \omega(\beta - i\gamma)}{\alpha + \omega(\beta + i\gamma)} \\ \Rightarrow |\lambda|^2 &= \frac{[(1 - \omega)\alpha - \omega\beta]^2 + (\omega\gamma)^2}{(\alpha + \omega\beta)^2 + (\omega\gamma)^2} \\ \therefore \text{分子-分母} &= \underbrace{((2 - \omega)\alpha)}_{>0} \underbrace{(-\omega\alpha - 2\omega\beta)}_{<0} < 0, \quad \therefore |\lambda|^2 < 1, \text{对} \forall \lambda \Rightarrow \rho(L_\omega) < 1 \end{aligned}$$

□

代码 1.4: sor_iteration.m

```
1 function [x, iter, error_history] = sor_iteration(A, b, x0, omega, max_iter,
    tol)
2 % 使用矩阵形式的松弛迭代法(SOR)求解线性方程组 Ax = b
3 %
4 % 输入:
5 %   A - 系数矩阵 (n x n)
6 %   b - 右端向量 (n x 1)
7 %   x0 - 初始猜测向量 (n x 1)
8 %   omega - 松弛因子 (0 < omega < 2, 默认: 1)
9 %   max_iter - 最大迭代次数 (默认: 1000)
10 %   tol - 容差 (默认: 1e-6)
11 %
12 % 输出:
13 %   x - 数值解
14 %   iter - 实际迭代次数
15 %   error_history - 每次迭代的误差历史
16
17 if nargin < 4
18     omega = 1;
19 end
```

```
20     if nargin < 5
21         max_iter = 1000;
22     end
23     if nargin < 6
24         tol = 1e-6;
25     end
26
27     % 检查松弛因子范围
28     if omega <= 0 || omega >= 2
29         warning('松弛因子应在区间 (0, 2) 内, 当前值: %f', omega);
30     end
31
32     n = length(b);
33     x = x0;
34     error_history = zeros(max_iter,1);
35
36     % 矩阵分解: A = D + L + U
37     D = diag(diag(A));           % 对角部分
38     L = tril(A, -1);             % 严格下三角部分
39     U = triu(A, 1);              % 严格上三角部分
40
41
42     for iter = 1:max_iter
43         x_old = x;
44
45         % SOR迭代: (D + \omega L)x(k) = [(1-\omega)D - \omega U]x(k-1) + \omega b
46         rhs = ((1-omega)*D - omega*U) * x_old + omega * b;
47
48         % (D + \omega L) 为下三角方阵, 回代法直接求解 (D + \omega L)x = rhs
49         x = zeros(n, 1);
50         for i = 1:n
51             x(i) = (rhs(i) - omega * L(i, 1:i-1) * x(1:i-1)) / (D(i,i) +
                    omega * L(i,i));
52         end
53
54         % 计算相对误差
55         error = norm(x - x_old, inf) / norm(x, inf);
56         error_history(iter) = error;
57
58         % 检查收敛
59         if error < tol
60             break;
61         end
62     end
63
64     % 截断误差历史数组
65     error_history = error_history(1:iter);
66 end
```

1.3.4 经典迭代格式的统一

1. 可逆方阵 $\tilde{A} \approx A$, 且 $\tilde{A}x = \tilde{b}$ 容易求解, 则

$$Ax = b \Leftrightarrow \tilde{A}x = (\tilde{A} - A)x + b \Leftrightarrow x^{(k+1)} = \tilde{A}^{-1}((\tilde{A} - A)x^{(k)} + b)$$

2. 选取矩阵 C , 使得

$$Ax^{(k+1)} - b = (I - AC)(Ax^{(k)} - b) \Leftrightarrow x^{(k+1)} = (I - CA)Ax^{(k)} + Cb$$

定理 1.3.7. $\|I - AC\| \leq r < 1$ (r 是常数) 时迭代收敛, $\|I - CA\| \leq r < 1$ (r 是常数) 时迭代也收敛。

证明:

$$\|(Ax^{(k)} - b)\| = \|(I - AC)^k(Ax^{(0)} - b)\| \leq \|I - CA\|^k \|(Ax^{(0)} - b)\|$$

由于 $\|I - AC\| \leq r < 1$, 因此当 $k \rightarrow \infty$ 时, 迭代收敛。

$$A(I - CA)A^{-1} = I - AC$$

$$\begin{aligned} \|(Ax^{(k)} - b)\| &= \|A(I - CA)A^{-1}(Ax^{(k-1)} - b)\| = \|A(I - CA)^{(k)}A^{-1}(Ax^{(0)} - b)\| \\ &\leq r^k \text{cond}(A) \|Ax^{(0)} - b\| \end{aligned}$$

由于 $\|I - CA\| \leq r < 1$, 因此当 $k \rightarrow \infty$ 时, 迭代收敛。 □

1.4 求解线性方程组的直接法

1.4.1 Gauss 消元法

Gauss 消元法

Gauss 消元法通过初等行变换将系数矩阵化为上三角矩阵, 然后回代求解。

设线性方程组 $Ax = b$, 其中 $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$ 。

1. 构造增广矩阵:

$$[A|b] = \left[\begin{array}{cccc|c} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & b_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} & b_n \end{array} \right]$$

2. 前向消元: 对 $k = 1, 2, \dots, n-1$

- 选取主元 a_{kk} (Gauss 列主元消元法中, 必要时进行行交换)
- 对 $i = k+1, \dots, n$, 计算乘数:

$$m_{ik} = \frac{a_{ik}}{a_{kk}}$$

- 对 $j = k, \dots, n+1$ (包括右端项):

$$a_{ij} \leftarrow a_{ij} - m_{ik}a_{kj}$$

消元过程可表示为矩阵乘法:

$$M_k A^{(k)} = A^{(k+1)}$$

其中

$$M_k = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -m_{k+1,k} & 1 & \\ & & \vdots & & \ddots \\ & & -m_{n,k} & & & 1 \end{bmatrix}$$

3. 回代求解:

$$x_n = \frac{b_n}{a_{nn}}$$

$$x_k = \frac{b_k - \sum_{j=k+1}^n a_{kj}x_j}{a_{kk}}, \quad k = n-1, n-2, \dots, 1$$

Gauss-Jordan 消元法

Gauss-Jordan 消元法通过初等行变换将系数矩阵化为对角矩阵, 直接求解。

设线性方程组 $Ax = b$, 构造增广矩阵:

$$[A|b] = \left[\begin{array}{cccc|c} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & b_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} & b_n \end{array} \right]$$

阶段一: 前向消元 (化为上三角形)

对 $k = 1, 2, \dots, n-1$:

对 $i = k+1, \dots, n$:

$$m_{ik} = \frac{a_{ik}}{a_{kk}}$$

对 $j = k+1, \dots, n$:

$$a_{ij} \leftarrow a_{ij} - m_{ik} \cdot a_{kj}$$

$$b_i \leftarrow b_i - m_{ik} \cdot b_k$$

矩阵形式表示为:

$$M_k A^{(k)} = A^{(k+1)}, \quad M_k b^{(k)} = b^{(k+1)}$$

其中

$$M_k = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -m_{k+1,k} & 1 & \\ & & \vdots & & \ddots \\ & & -m_{n,k} & & 1 \end{bmatrix}$$

阶段二：反向消元（化为对角形）

对 $i = n, n-1, \dots, 1$:

$$b_i \leftarrow \frac{b_i}{a_{ii}}$$

对 $j = 1, 2, \dots, i-1$:

$$b_j \leftarrow b_j - a_{ji} \cdot b_i$$

矩阵形式表示为经过一系列初等行变换后，增广矩阵变为：

$$[D|b'] = \left[\begin{array}{cccc|c} a_{11} & 0 & \cdots & 0 & b'_1 \\ 0 & a_{22} & \cdots & 0 & b'_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & a_{nn} & b'_n \end{array} \right]$$

1.4.2 解的形式

最终解向量为：

$$x = \begin{bmatrix} b'_1 \\ b'_2 \\ \vdots \\ b'_n \end{bmatrix}$$